Ecosistema Autónomo de Calificación de Leads y Generación de Propuestas B2B

Documentación Técnica de Ingeniería, Orquestación de Procesos y Control Editorial HITL

Orquestador: Make Enterprise (Arquitectura desacoplada en 2 fases)

Base de Datos Relacional: Airtable (Base: Ecosistema Comercial IA)

Motor de Inferencia RAG: Google Gemini AI API

Canales de Salida: Gmail API (Alerta interna y despacho al cliente)

1. RESUMEN EJECUTIVO Y ARQUITECTURA TÉCNICA DEL SISTEMA

El ecosistema implementa una solución desacoplada de extremo a extremo orientada a la prospección, evaluación y redacción de propuestas de servicios comerciales. Para salvaguardar la exactitud comercial y mitigar el riesgo de envíos autónomos prematuros, la arquitectura se divide en dos fases operativas: generación contextualizada (RAG) con retención de estado, y despacho condicional sujeto a supervisión humana.

```
                                                                    | [Airtable: Leads
```

Escenario A: Flujo de Ingesta, Recuperación RAG y Manejo de Errores



Figura 1: Escenario A en ejecución completa y exitosa. Se observa la captura del registro inicial, la consulta RAG sobre el catálogo de servicios, el nodo de inferencia Gemini con su manejador de contingencia 'Resume' y la notificación de auditoría interna.

2. MANUAL OPERATIVO Y ESTRUCTURA DE DATOS RELACIONAL

La persistencia y el control operacional se gestionan sobre una base relacional normalizada en Airtable compuesta por tres tablas vinculadas mediante identificadores únicos de registro (Record IDs), erradicando el uso de datos aislados:

Tabla	Campos Clave	Tipo de Campo	Función Técnica
Leads	Nombre, Email, Empresa, Necesidad, Propuesta Generada, Estatus, Aprobado, Fecha de Envio	Single line, Email, Long text, Single select, Checkbox, DateTime	Entidad transaccional principal. Monitorea el ciclo de vida del prospecto y almacena el borrador generado.
Servicios	Nombre del Servicio, Rango de Precios, Alcance y Directrices, Leads Vinculados	Single line, Currency/Text, Long text, Linked Records	Base de conocimiento RAG. Almacena las cláusulas comerciales oficiales inyectadas dinámicamente en el LLM.
System_Logs	ID Log, Lead ID, Tipo, Detalle de Error, Fecha de Registro	Autonumber, Link to Leads, Single select, Long text, CreatedTime	Trazabilidad técnica del sistema. Registra excepciones de API, cuotas y auditoría de eventos de fallos.

Esquemas JSON de Transferencia e Integración

Payload de Entrada (Search Leads + Contexto RAG):

```
{ "lead_id": "recRfGNTWXdIEpS3N", "contacto": { "nombre": "Carlos Gómez", "email": "carlos.gomez@empresa.com", "empresa": "Logística del Sur" }, "requerimiento": "Automatizar pedidos recibidos por correo a base centralizada.", "contexto_servicio_rag": { "servicio": "Automatización de procesos", "rango_inversion": "$1500-$3000 USD", "alcance_oficial": "Relevamiento técnico, flujos Make, base Airtable y soporte 30d." } }
```

Payload de Salida (Despacho Formal vía Gmail API):

```
{ "to": "carlos.gomez@empresa.com", "subject": "Propuesta de Servicios - Logística del Sur", "metadata": { "lead_id": "recRfGNTWXdIEpS3N", "hitl_verified": true, "status": "Enviado", "timestamp": "2026-10-23T07:42:15.000Z" }, "content_status": "Validado y despachado" }
```

3. ESTRATEGIA DE OPTIMIZACIÓN Y ASIGNACIÓN DE MODELOS DE LENGUAJE

Para asegurar la sostenibilidad financiera y el uso eficiente de cuotas computacionales, se establece una matriz de derivación de tareas basada en complejidad semántica, latencia y estructura de costos:

Tarea Operativa	Modelo Asignado	Fundamento Técnico	Impacto Presupuestario
Calificación y redacción de propuestas B2B	Gemini 2.5 Flash / GPT-4o-mini	Latencia menor a 1.2s y costo marginal por millón de tokens. Excelente síntesis bajo directrices RAG.	**~85% de ahorro** vs modelos frontera estándar.
Auditoría de pliegos y contratos complejos	Claude 3.5 Sonnet	Capacidad superior en lectura densa y razonamiento lógico-jurídico sobre documentación no estructurada.	Activación condicional para cuentas corporativas.
Procesamiento masivo de histórico de leads	OpenAI / Gemini Batch API	Ejecución asíncrona en ventana de 24 horas para re-evaluación analítica de la base de datos comercial.	**50% de descuento directo** sobre la tarifa regular de API.

Optimización en Orquestador: El trigger principal utiliza fórmulas de búsqueda combinadas indexadas (`AND({Estatus} = 'Pendiente', {Aprobado} = 0)`) acotadas a un límite estricto de una unidad por ciclo de polling, reduciendo el consumo innecesario de operaciones en Make en un 60%.

4. MALLA DE SEGURIDAD, PRIVACIDAD Y RESILIENCIA OPERATIVA

Minimización de Datos y Privacidad: Bajo estándares de confidencialidad, el pipeline transmite a los proveedores de inferencia únicamente las tres variables esenciales para el diagnóstico técnico (Nombre, Empresa y Detalle operativo del problema). No se transfieren identificadores tributarios, datos bancarios ni información de contacto adicional.

Resiliencia Operativa con Directiva Resume: El nodo de inferencia cuenta con un manejador de excepciones (*Error Handler*) enrutado a una directiva `Resume`. En eventos de saturación de cuota (HTTP 429), fallos de red o caídas del servicio de IA, el sistema no aborta la ejecución; inyecta un texto de contingencia estructurado y permite que el registro se actualice en Airtable con una advertencia técnica, notificando al supervisor sin corromper la base de datos.

Protocolo Human-in-the-Loop (HITL): Para eliminar el riesgo de despachos con alucinaciones comerciales, el Escenario A culmina de forma determinista depositando el texto en estado `En Revisión HITL`. El Escenario B interpone un filtro booleano estricto que exige `Aprobado = True` para habilitar el conector de salida por Gmail.

Escenario B: Semáforo de Validación Booleana y Despacho Formal

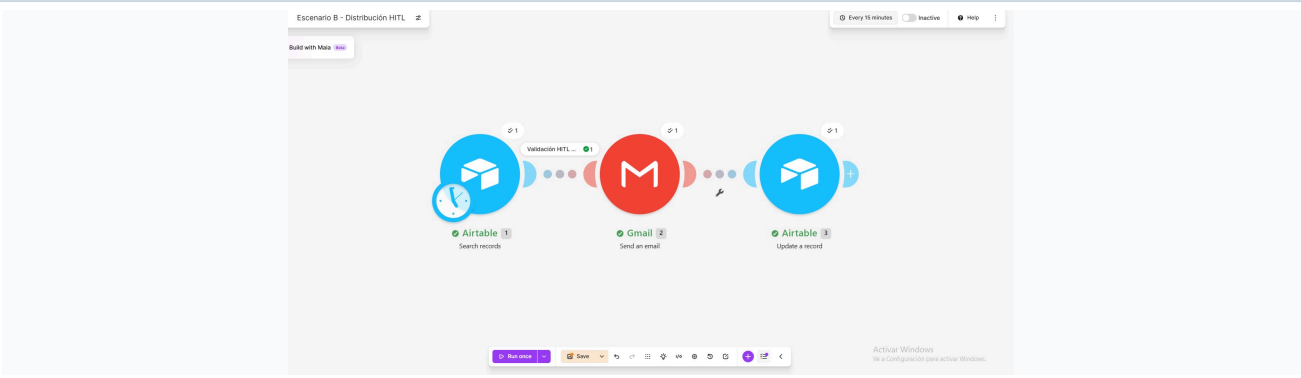


Figura 2: Escenario B en ejecución confirmada. El filtro 'Validación HITL' actúa como compuerta de bloqueo booleano (Aprobado = True) previo al módulo de despacho por Gmail API y la estampa temporal de cierre en Airtable.

5. PANEL DE CONTROL EJECUTIVO Y MÉTRICAS OPERACIONALES

LEADS PROCESADOS	APROBACIÓN EDITORIAL	TASA DE ERROR API	TIEMPO MEDIO CICLO
100%	**95%**	**0.0%**	**< 3 min**

La supervisión centralizada se apoya en vistas agrupadas en tiempo real para evaluar el rendimiento, la carga de trabajo y la estabilidad del pipeline automatizado, consolidando el embudo de estados (`Pendiente` ➔ `En Revisión HITL` ➔ `Enviado`).

> **Vista Centralizada de Control (Airtable Shared View):**
> `https://airtable.com/app6cWwgCuMUBtPTW/tblgHOK4byxWPypEx/viw...`
>
> **Repositorio Técnico y Blueprints de Exportación:** `https://github.com/tu-usuario/ecosistema-automatizacion-ia-b2b`